

TD 4 : TESTS ET IC

Préambule :

On rappelle que :

1. $\chi^2(n)$ désigne la loi d'une somme des carrés de n variables aléatoires $\mathcal{N}(0, 1)$ indépendantes :

Si $X_i \stackrel{i.i.d.}{\sim} \mathcal{N}(0, 1)$, alors :

$$\sum_{i=1}^n X_i^2 \sim \chi^2(n).$$

2. **On admet** que dans un modèle gaussien i.i.d. $\mathcal{N}(m, \sigma^2)$, l'estimateur non biaisé de la variance

$\hat{S}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ vérifie :

$$(n-1) \frac{\hat{S}_n^2}{\sigma^2} \sim \chi^2(n-1) \text{ et } \hat{S}_n^2 \coprod \bar{X}.$$

3. $\text{St}(n)$ désigne la loi du quotient entre une variable aléatoire $\mathcal{N}(0, 1)$ et la racine d'une $\chi^2(n)$ normalisée par le nombre de degrés de liberté, indépendantes :

si $Z \sim \mathcal{N}(0, 1), U \sim \chi^2(n), Z \coprod U$:

$$\frac{Z}{\sqrt{\frac{U}{n}}} \sim \text{St}(n).$$

4. **On rappelle** que dans un modèle gaussien $\mathcal{N}(m, \sigma^2)$, on a

$$\sqrt{n} \frac{\bar{X} - m}{\hat{S}_n} \sim \text{St}(n-1).$$

5. Si Y est issu d'une loi discrète donnée par $\forall k \in [1, K], \mathbb{P}(Y = k) = p_k$, que Y_1, \dots, Y_N est un échantillon i.i.d. de même loi que Y , et qu'on note $O_k = \sum_{i=1}^N \mathbb{1}_{Y_i=k}$, et $E_k = Np_k$, alors :

$$\sum_{k=1}^K \frac{(O_k - E_k)^2}{E_k} \xrightarrow{\mathcal{L}} \chi^2(K-1) \text{ (quand } N \text{ tend vers l'infini)}.$$

6. Si (X, Y) désigne un couple de variables aléatoires discrètes indépendantes, à valeurs dans $[1, K_1] \times [1, K_2]$, que $(X_1, Y_1), \dots, (X_N, Y_N)$ est un échantillon i.i.d. de même loi que (X, Y) , et qu'on note

$O_{k_1, k_2} = \sum_{i=1}^N \mathbb{1}_{X_i=k_1, Y_i=k_2}$, et $M_{k_1} = \sum_k O_{k_1, k}$ et $L_{k_2} = \sum_k O_{k, k_2}$, et $E_{k_1, k_2} = \frac{M_{k_1} L_{k_2}}{N}$ on a :

$$\sum_{k_1, k_2=1}^{K_1, K_2} \frac{(O_{k_1, k_2} - E_{k_1, k_2})^2}{E_{k_1, k_2}} \xrightarrow{\mathcal{L}} \chi^2((K_1-1)(K_2-1)).$$

7. La loi de Fisher $F(n_1, n_2)$ désigne un rapport de deux χ^2 à n_1, n_2 degrés de libertés, renormalisés par le nombre de degrés de liberté : Si $U_1 \sim \chi^2(n_1)$ et $U_2 \sim \chi^2(n_2)$, alors :

$$\frac{\frac{U_1}{n_1}}{\frac{U_2}{n_2}} \sim F(n_1, n_2).$$

8. On rappelle qu'une combinaison affine de variables aléatoires de loi normales indépendantes reste de loi normale.

9. On rappelle le TCL : Si $(X_i)_{i \in \mathbb{N}}$ est une suite de variables aléatoires i.i.d. d'espérance m et de variance σ^2 , alors

$$\sqrt{n} \frac{\bar{X} - m}{\sigma} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1).$$

10. On rappelle enfin que grâce au lemme de Slutsky, on peut remplacer l'écart-type dans la convergence précédente par une estimation consistante de ce dernier.

Exercice 1 IC et test bilatéraux vs unilatéraux

On mesure la concentration en nitrates dans 30 points d'un cours d'eau. On modélise ces mesures comme des réalisations i.i.d. d'une loi normale d'espérance m inconnue et de variance σ^2 inconnue. Les mesures ont donné $\bar{x} = 46.7 \text{ mg.L}^{-1}$ et $\hat{s}^2 = 81.3 \text{ mg}^2.\text{L}^{-2}$.

1. Donner un intervalle de confiance pour m , au degré de confiance 99%
2. Donner la p -valeur du test

$$H_0 : m = 50 \text{ mg.L}^{-1}$$

$$H_1 : m \neq 50 \text{ mg.L}^{-1}$$

3. Le test précédent est-il rejeté au niveau $\alpha = 0.05$?
4. Le taux ne doit surtout pas dépasser 50 mg.L^{-1} , sous peine de hauts risques sanitaires. Expliquer pourquoi on choisira de tester

$$H_0 : m \geq 50 \text{ mg.L}^{-1}$$

$$H_1 : m < 50 \text{ mg.L}^{-1}$$

plutôt que dans l'autre sens.

5. Donner la p -valeur du test précédent.
6. Ce test est-il rejeté au niveau $\alpha = 0.05$? et au niveau $\alpha = 0.01$?
7. Donner un intervalle de confiance unilatéral à droite (de la forme $]-\infty, A])$ pour m , au degré de confiance 99%.
8. Aurait-on pu utiliser cet intervalle de confiance pour effectuer le test au niveau 1%

Exercice 2 Test sur la variance et la moyenne

On vous demande de tester la qualité de vis devant correspondre aux caractéristiques suivantes :

- Longueur : 40mm
- Diamètre : 3mm
- Diamètre de la tête : 6.5mm

Le fabricant annonce que l'écart-type de toutes les mesures est de 0.5mm. Vous procédez à 25 mesures (L_i, d_i, D_i) de la longueur, diamètre, et diamètre de la tête, et vous obtenez

$$\bar{L} = 40.2, \bar{d} = 3.1, \bar{D} = 6.4, \hat{S}_{L,n} = 0.54, \hat{S}_{d,n} = 0.25, \hat{S}_{D,n} = 0.60$$

On modélise les données comme issues de lois normales indépendantes.

1. Tester (au niveau 5%) pour chaque dimension, si la variance est celle donnée par le fabricant, et donner les p -valeurs associées.
2. Tester (au niveau 5%) si les dimensions sont celles données par le fabricant, donner les p -valeurs associées.
3. Donner les intervalles de confiance bilatéraux pour la variance, au degré de confiance de 95%.
4. Donner les intervalles de confiance unilatéraux à droite pour la variance (de la forme $[0, A])$, au degré de confiance de 95%.
5. Refaire le test (au niveau 5%) sur le diamètre en considérant la variance connue (et en prenant celle donnée par le fabricant).
6. Comment pourriez-vous corriger le fait d'avoir voulu faire plusieurs tests simultanément pour contrôler la probabilité qu'au moins un de ces tests soit rejeté à tort ? Est-ce pertinent dans ce cadre là ?

Exercice 3 Statistiques de tests

Soient $X_1, \dots, X_{n_1} \stackrel{i.i.d.}{\sim} \mathcal{N}(m_1, \sigma^2)$, et $Y_1, \dots, Y_{n_2} \stackrel{i.i.d.}{\sim} \mathcal{N}(m_2, \sigma^2)$, des échantillons indépendants de même variance σ^2 . On note \bar{X}, \bar{Y} les moyennes empiriques associées, et $\hat{S}_{X,n_1}^2, \hat{S}_{Y,n_2}^2$ les estimateurs sans biais de la variance associés.

1. En admettant le point 2 et 3 du préambule, montrer le point 4 du préambule.
2. En utilisant le point 1 du préambule, donner la loi d'une somme de χ^2 indépendantes, à respectivement n_1 et n_2 degrés de liberté.
3. En déduire la loi de $\frac{(n_1-1)\hat{S}_{X,n_1}^2 + (n_2-1)\hat{S}_{Y,n_2}^2}{\sigma^2}$.
4. Calculer la loi de $\sqrt{n'} \frac{\bar{X} - m_1 - (\bar{Y} - m_2)}{\sigma}$, où $n' = \frac{1}{\frac{1}{n_1} + \frac{1}{n_2}}$.

5. En utilisant le point 3 du préambule, et les deux dernières questions, montrer que $U = \sqrt{n'} \frac{\bar{X} - m_1 - (\bar{Y} - m_2)}{\sqrt{\frac{(n_1-1)\hat{S}_{X,n_1}^2 + (n_2-1)\hat{S}_{Y,n_2}^2}{n_1 + n_2 - 2}}}$

vérifie

$$U \sim \text{St}(n_1 + n_2 - 2).$$

Exercice 4 Test de comparaison de variances et de moyenne

On a mesuré les dimensions d'une tumeur chez des souris traitées ou non avec une substance antitumorale. On modélise les données comme issues de lois normales indépendantes d'espérances respectives m_1 et m_2 , et de variances respectives σ_1^2 et σ_2^2 . On a obtenu les résultats suivants :

Souris témoins : $n_1 = 20$, $\bar{X} = 7,075\text{cm}^2$, $\hat{S}_{X,20} = 0,576\text{cm}^2$.

Souris traitées : $n_2 = 18$, $\bar{Y} = 5,850\text{cm}^2$, $\hat{S}_{Y,18} = 0,614\text{cm}^2$.

1. Montrer que si $\sigma_1^2 = \sigma_2^2$, alors on a

$$W := \frac{\hat{S}_X^2}{\hat{S}_Y^2} \sim F(n_1 - 1, n_2 - 1).$$

2. Tester (au niveau 5%, et en donnant la p-valeur) :

$$H_0 : \sigma_1 = \sigma_2$$

$$H_1 : \sigma_1 \neq \sigma_2$$

3. Tester (au niveau 5%, et en donnant la p-valeur), en supposant l'égalité des variances, et en utilisant l'exercice précédent :

$$H_0 : m_1 = m_2$$

$$H_1 : m_1 \neq m_2$$

4. Tester (au niveau 5%, et en donnant la p-valeur), en supposant l'égalité des variances, et en utilisant l'exercice précédent :

$$H_0 : m_1 \geq m_2$$

$$H_1 : m_1 < m_2$$

Exercice 5 Test de comparaison de variances et de moyenne 2

Le pH (degré d'acidité) a été mesuré dans deux types de solutions chimiques A et B. Dans la solution A, six mesures ont été faites, avec un pH moyen de 7,52 et un écart-type estimé de 0,024. Dans la solution B, cinq mesures ont été faites, avec un pH moyen de 7,49 et un écart-type estimé de 0,032. On modélise les données comme issues de lois normales indépendantes. Déterminer si, au niveau 0,05, les deux solutions ont des pH différents (donner la p-valeur).

Exercice 6 Test sur la variance

On veut évaluer la performance de deux appareils de mesures de pression, à haute-pression. Pour cela, on travaille à pression constante et contrôlée de $m_0 = 100$ bars, et on prend 20 mesures avec chaque appareil, et calcule leur estimateur de la variance à espérance connue, \hat{V}_1^2 et \hat{V}_2^2 (définies par $\hat{V}^2 := \frac{1}{n} \sum_{i=1}^n (X_i - m_0)^2$.)

On modélise les mesures faites avec l'appareil i comme des réalisations indépendantes de lois normales d'espérance m_0 et de variance σ_i^2 . Les observations ont donné $\hat{v}_1^2 = 0.0009$ et $\hat{v}_2^2 = 0.0019$.

1. Calculer la p-valeur du test :

$$H_0 : \sigma_1^2 \geq \sigma_2^2$$

$$H_1 : \sigma_1^2 < \sigma_2^2$$

2. Donner aussi la p-valeur du test :

$$H_0 : \sigma_1^2 \leq \sigma_2^2$$

$$H_1 : \sigma_1^2 > \sigma_2^2$$